



Projet Master 1 SSD

Un modèle pour les nids de mouettes

Rédigé par

CARVAILLO Thomas

CÔME Olivier

PRALON Nicolas

Encadrante : Elodie BRUNEL-PICCININI

IMAG
INSTITUT MONTPELLIERAIN
ALEXANDER GROTHENDIECK




Table des matières

Introduction	2
1 Modélisation du problème	3
1.1 Modélisation du problème	3
1.2 Une histoire de densités	4
1.3 Première approche du problème	5
1.4 Résolution du problème	7
2 L'algorithme EM	12
2.1 Présentation laconique et pseudo-code	12
2.2 Un théorème	13
Bibliographie	15
A Annexe	16

Introduction

Chapitre 1

Modélisation du problème

1.1 Modélisation du problème

Dans toute la suite de l'étude on considère seulement des variables aléatoires réelles.
Commençons tout d'abord par donner une première définition, qui est au coeur du présent projet.

Définition 1 (Loi de mélange). On appelle loi de mélange toute loi dont la densité s'écrit sous la forme d'une combinaison convexe de diverses densités.

Soient X_1, \dots, X_J , J var de densité respective par rapport à la mesure de Lebesgue $f_1(x), \dots, f_J(x)$. On appelle loi de mélange toute fonction f intégrable telle que :

$$\begin{aligned} f : R &\rightarrow R_+ \\ : x &\mapsto \sum_{i=1}^J \alpha_i f_i(x) , \quad \alpha_i \in \mathbb{R} \end{aligned}$$

Plaçons maintenant un cadre, au problème énoncé en introduction, et introduisons les variables aléatoires suivantes :

- ✂ On définit X , la variable aléatoire modélisant la taille des nids
- ✂ On définit Z , la variable aléatoire discrète représentant l'espèce de mouette observé

Proposition 1. *La variable Z est discrète et à valeur dans un sous-ensemble fini de \mathbb{N} , elle suit donc une loi*

$$\sum_{j=1}^J \alpha_j \delta_j$$

où J représente le nombre d'espèce de mouettes considéré et les $\alpha(j)$ sont des réels, positifs stricts, représentant la proportion de nids de l'espèce j , tels que $\sum_{j=1}^J \alpha_j = 1$.

Enfin, nous nous placerons sous les hypothèses suivantes :

Hypothèse 1. *Nous supposons pour chaque espèce que, la taille de leurs nids suit une loi normale. On note $\forall j \in \llbracket 1, J \rrbracket$, γ_{μ_j, v_j} sa densité.*

Il s'ensuit de la définition et de l'hypothèse précédente, la proposition suivante.

Proposition 2. *La distribution de la taille des nids de mouettes, i.e. X , admet pour densité, au point x et par rapport à la mesure de Lebesgue sur \mathbb{R} , la fonction f_θ définie comme suit*

$$f_\theta(x) = \sum_{j=1}^J \alpha_j \gamma_{\mu_j, v_j}(x)$$

Démonstration. On vérifie que l'on obtient bien une densité de probabilité, la forme de cette dernière étant la conséquence directe de la définition de la variable aléatoire X :

$$\int_{\mathbb{R}} f_{\theta}(x) dx = \int_{\mathbb{R}} \sum_{j=1}^J \alpha_j \gamma_{\mu_j, v_j}(x) dx = \sum_{j=1}^J \alpha_j \int_{\mathbb{R}} \gamma_{\mu_j, v_j}(x) dx = \sum_{j=1}^J \alpha_j = 1$$

2

Remarque 1. Puisque que X est intégrale et Z également, on peut généraliser la proposition précédente : $\forall j \in \llbracket 1, J \rrbracket$, la loi de conditionnelle de X sachant que $\{Z = j\}$ admet pour densité par rapport à la mesure de Lebesgue, la fonction $f_{\theta}(x|Z = j) := \gamma_{\mu_j, v_j}(x) \forall x \in \llbracket \mathbb{R} \rrbracket$.

Il reste maintenant à poser l'hypothèse suivante.

Hypothèse 2. On note $\Theta := \{\theta = (\alpha_j, \mu_j, v_j)_{1 \leq j \leq J} \text{ tels que } \alpha_j > 0 \forall j \in \llbracket 1, J \rrbracket \text{ et } \sum_{j=1}^J \alpha_j = 1\}$.

On supposera qu'il existe $\theta \in \Theta$ tel que les paramètres de la loi de X sont donnés par θ .

Le but de ce projet sera d'étudier des méthodes permettant l'estimation des divers paramètres de cette densité. Nous détonerons par $\theta := (\alpha_j, \mu_j, v_j)_{1 \leq j \leq J}$ les vecteurs des ces dits paramètres.

1.2 Une histoire de densités

Introduisons une dernière densité et une dernière probabilité, qui nous seront fort utile quant à l'expression des Log-vraisemblances conditionnelles :

Proposition 3. Nous avons les résultats suivant :

1. La densité du vecteur aléatoire (X, Z) nous est donnée par :

$$\begin{aligned} h_{\theta} : \mathbb{R} \times \{1, \dots, J\} &\rightarrow \mathbb{R}_+ \\ (x, j) &\mapsto \alpha_j \times \gamma_{\mu_j, v_j}(x) \end{aligned}$$

2. La loi conditionnelle de Z sachant $\{X = x\}$ nous est donnée par :

$$\mathbb{P}_{\theta}(Z = j|X = x) = \frac{\gamma_{\mu(z), v(z)} \times \alpha_z}{\sum_{i=1}^J \alpha_i \times \gamma_{\mu(i), v(i)}(x)}$$

Démonstration. Par propriété des lois conditionnelles, nous avons que

$$h_{\theta}(x, j) = f_{\theta}(x|Z = j) \times \mathbb{P}_{\theta}(Z = j) = f_{\theta}(x) \times \mathbb{P}_{\theta}(Z = j|X = x)$$

De ceci, nous déduisons aisément la densité de la loi du vecteur aléatoire (X, Z) :

$$h_{\theta}(x, j) = \alpha_j \times \gamma_{\mu_j, v_j}(x)$$

Puis la densité de la loi conditionnelle de Z sachant $\{X = x\}$:

$$\mathbb{P}_{\theta}(Z = j|X = x) = \frac{\gamma_{\mu(z), v(z)} \times \alpha_z}{\sum_{i=1}^J \alpha_i \times \gamma_{\mu(i), v(i)}(x)}$$

2

Remarque 2. Nous pouvons dès à présent noter que pour un échantillon X_1, \dots, X_n iid de même loi que X , nous avons

$$\forall i \in \llbracket 1, n \rrbracket, h_{\theta}(X_i, j) = f_{\theta}(X_i) \times \mathbb{P}_{\theta}(Z = j|X = X_i)$$

Ceci nous sera utile dans la suite.

Nous allons dès à présent nous intéresser à l'estimation de ces paramètres.

1.3 Première approche du problème

Afin de résoudre le problème posé, une approche naturelle consiste à déterminer par maximum de vraisemblance les paramètres recherchés. Toute fois cette approche comme nous allons le constater, est difficilement applicable.

On considère dans toute la suite les échantillons X_1, \dots, X_n iid de même loi que X et Z_1, \dots, Z_n iid de même loi que Z .

On définit \mathcal{L}_{obs} la log-vraisemblance du modèle d'échantillonnage de X , nous obtenons ainsi

Définition 2. La log-vraisemblance des observations s'écrit

$$\mathcal{L}_{obs}(\theta, X_1, \dots, X_n) := \ln \left(\prod_{i=1}^n f_{\theta}(X_i) \right) = \sum_{i=1}^n \ln \left(\sum_{j=1}^J \alpha_j \gamma_{\mu_j, v_j}(X_i) \right)$$

Nous voyons dès lors que l'existence d'une expression analytique du maximum de la log-vraisemblance n'est pas assurée. Il est donc nécessaire de trouver un moyen d'approcher les valeurs des différents estimateurs.

Pour ce faire, on peut s'intéresser modèle d'échantillonnage du couple (X, Z) , car le paramètre θ du modèle reste inchangé.

Afin de simplifier les calculs, on se propose de réécrire la fonction de Log-vraisemblance de ce nouveau modèle.

Proposition 4 (Fonction de Log-vraisemblance). *La Log-vraisemblance du modèle s'écrit*

$$\mathcal{L}_{\theta}(X_1, \dots, X_n, Z_1, \dots, Z_n) = \sum_{j=1}^J |A_j| \ln(\alpha_j) + \sum_{j=1}^J \sum_{i \in A_j} \ln(\gamma_{\mu_j, v_j}(X_i))$$

où les A_j sont définis par $A_j := \{i \in \llbracket 1, n \rrbracket \text{ tels que } Z_i = j\}$ *i.e.* $\bigcup_{j=1}^J A_j = \llbracket 1, n \rrbracket$

Démonstration. La Log-vraisemblance du modèle s'écrit :

$$\begin{aligned} \mathcal{L}_{\theta}(X_1, \dots, X_n, Z_1, \dots, Z_n) &= \ln \left(\prod_{i=1}^n h_{\theta}(X_i, Z_i) \right) \\ &= \ln \left(\prod_{i=1}^n \alpha_{Z_i} \gamma_{\mu_{Z_i}, v_{Z_i}}(X_i) \right) \\ &= \sum_{i=1}^n \ln(\alpha_{Z_i}) + \ln(\gamma_{\mu_{Z_i}, v_{Z_i}}(X_i)) \end{aligned}$$

Z_i est à valeur dans $\llbracket 1, J \rrbracket$, on partitionne donc $I := \llbracket 1, n \rrbracket$ comme $I = \bigcup_{j=1}^J A_j$ pour obtenir

$$\begin{aligned} \mathcal{L}_{\theta}(X_1, \dots, X_n, Z_1, \dots, Z_n) &= \sum_{j=1}^J \sum_{i \in A_j} \ln(\alpha_{Z_i}) + \sum_{j=1}^J \sum_{i \in A_j} \ln(\gamma_{\mu_j, v_j}(X_i)) \\ &= \sum_{j=1}^J \sum_{i \in A_j} \ln(\alpha_j) + \sum_{j=1}^J \sum_{i \in A_j} \ln(\gamma_{\mu_j, v_j}(X_i)) \\ &= \sum_{j=1}^J |A_j| \ln(\alpha_j) + \sum_{j=1}^J \sum_{i \in A_j} \ln(\gamma_{\mu_j, v_j}(X_i)) \end{aligned}$$

Nous pouvons dès lors maximiser la log-vraisemblance afin d'obtenir les estimateurs souhaités :

Proposition 5 (Estimateurs). *Les estimateurs du maximum de vraisemblance $\hat{\alpha}_j$ (resp. $\hat{\mu}_j$, et \hat{v}_j) de α_j (resp. μ_j et v_j) sont donnés par*

$$\begin{aligned}\hat{\alpha}_j &= \frac{|A_j|}{n} \\ \hat{\mu}_j &= \frac{\sum_{i \in A_j} X_i}{|A_j|} \\ \hat{v}_j &= \frac{\sum_{i \in A_j} (X_i - \hat{\mu}_j)^2}{|A_j|}\end{aligned}$$

Démonstration. Soit $\theta = (\alpha_j, \mu_j, v_j)_{j \in \llbracket 1, J \rrbracket}$. Il s'agit de déterminer

$$\operatorname{argmax}_{\theta \in \mathbb{R}^{3J}, \sum_{j=1}^J \alpha_j = 1} \left(\sum_{j=1}^J |A_j| \ln(\alpha_j) + \sum_{j=1}^J \sum_{i \in A_j} \ln(\gamma_{\mu_j, v_j}(x_i)) \right)$$

Nous avons donc à résoudre un programme de minimisation d'une fonction convexe sur un convexe avec une contrainte égalité, il est ainsi naturel de faire appel au Lagrangien.

Ce dernier s'écrit

$$\begin{aligned}L(\theta) &= \sum_{j=1}^J |A_j| \ln(\alpha_j) + \sum_{j=1}^J \sum_{i \in A_j} \ln(\gamma_{\mu_j, v_j}(x_i)) - \lambda \times \left(\sum_{j=1}^J \alpha_j - 1 \right) \\ &= \sum_{j=1}^J |A_j| \ln(\alpha_j) + \sum_{j=1}^J \sum_{i \in A_j} \ln \left(\frac{1}{\sqrt{2\pi v_j}} \exp \left(-\frac{(x_i - \mu_j)^2}{2v_j} \right) \right) - \lambda \times \left(\sum_{j=1}^J \alpha_j - 1 \right) \\ &= \sum_{j=1}^J |A_j| \ln(\alpha_j) + \sum_{j=1}^J \sum_{i \in A_j} \left(\frac{-1}{2} \ln(2\pi v_j) - \frac{(x_i - \mu_j)^2}{2v_j} \right) - \lambda \times \left(\sum_{j=1}^J \alpha_j - 1 \right)\end{aligned}$$

Il reste maintenant à résoudre le système suivant, afin d'obtenir le vecteur $\hat{\theta} := (\hat{\alpha}_j, \hat{\mu}_j, \hat{v}_j)_{j \in \llbracket 1, J \rrbracket}$ solution du programme.

$$\begin{cases} \frac{|A_j|}{\hat{\alpha}_j} - \lambda &= 0 \quad \forall j \in \llbracket 1, J \rrbracket \\ \sum_{i \in A_j} (x_i - \hat{\mu}_j) / \hat{v}_j &= 0 \quad \forall j \in \llbracket 1, J \rrbracket \\ \sum_{i \in A_j} \frac{-0.5 \times 2 \times \pi}{2\pi \hat{v}_j} + \frac{(x_i - \hat{\mu}_j)^2}{2\hat{v}_j^2} &= 0 \quad \forall j \in \llbracket 1, J \rrbracket \\ \sum_{j=1}^J \hat{\alpha}_j &= 1 \end{cases}$$

Ceci équivaut à

$$\begin{cases} \frac{|A_j|}{\hat{\alpha}_j} &= \lambda \quad \forall j \in \llbracket 1, J \rrbracket \\ \sum_{i \in A_j} x_i &= \sum_{i \in A_j} \hat{\mu}_j \quad \forall j \in \llbracket 1, J \rrbracket \\ \sum_{i \in A_j} (x_i - \hat{\mu}_j)^2 &= \sum_{i \in A_j} \hat{v}_j \quad \forall j \in \llbracket 1, J \rrbracket \\ \sum_{j=1}^J \hat{\alpha}_j &= 1 \end{cases} \Leftrightarrow \begin{cases} \frac{|A_j|}{\hat{\alpha}_j} &= \lambda \quad \forall j \in \llbracket 1, J \rrbracket \\ \sum_{i \in A_j} \frac{x_i}{|A_j|} &= \hat{\mu}_j \quad \forall j \in \llbracket 1, J \rrbracket \\ \sum_{i \in A_j} \frac{(x_i - \hat{\mu}_j)^2}{|A_j|} &= \hat{v}_j \quad \forall j \in \llbracket 1, J \rrbracket \\ \sum_{j=1}^J \hat{\alpha}_j &= 1 \end{cases}$$

En sommant les J premières lignes du système, on obtient $\sum_{j=1}^J |A_j| = \sum_{j=1}^J \hat{\alpha}_j \lambda$, i.e. $\lambda = n$. En injectant ceci dans le précédent système, on obtient finalement ce qui était annoncé :

$$\begin{cases} \hat{\alpha}_j &= \frac{|A_j|}{n} \quad \forall j \in \llbracket 1, J \rrbracket \\ \hat{\mu}_j &= \sum_{i \in A_j} \frac{x_i}{|A_j|} \quad \forall j \in \llbracket 1, J \rrbracket \\ \hat{v}_j &= \sum_{i \in A_j} \frac{(x_i - \hat{\mu}_j)^2}{|A_j|} \quad \forall j \in \llbracket 1, J \rrbracket \end{cases}$$

1.4 Résolution du problème

L'approche par le modèle d'échantillonnage de (X, Z) étant une bonne manière de résoudre théoriquement le problème, il en est moins quant à sa possible application. Les nids de mouettes pouvant être très similaires, il est très probable que l'observation de l'espèce ayant construit le nid n'est pas aisée à identifier. Il convient donc de déterminer une alternative à notre approche, tout en essayant de rester proche de toute la démarche effectuée dans la section précédente.

Une façon de faire cela est d'étudier l'espérance conditionnelle de la Log-vraisemblance du modèle d'échantillonnage sachant l'observation de l'échantillon X_1, \dots, X_n , elle constitue la meilleure approximation de la log-vraisemblance du modèle, par rapport à ce qui est observable i.e. X_1, \dots, X_n .

Définition 3 (log-vraisemblance conditionnelle). On définit la log-vraisemblance $\mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n)$ conditionnelle par

$$\mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n) = \mathbb{E}_{\tilde{\theta}}[\mathcal{L}_{\theta}(X_1, \dots, X_n, Z_1, \dots, Z_n) | X_1, \dots, X_n]$$

Nous allons maintenant travailler sur l'expression de la log-vraisemblance conditionnelle et en donner une expression simplifiée, qui nous sera fort utile ultérieurement, et une expression plus substantielle, qui nous sera immédiatement utile.

Proposition 6. *Nous avons*

$$\mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n) = \sum_{i=1}^n \sum_{j=1}^J \ln(h_{\theta}(X_i, j)) \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)$$

Démonstration. En effet

$$\begin{aligned} \mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n) &= \mathbb{E}_{\tilde{\theta}}[\mathcal{L}_{\theta}(X_1, \dots, X_n, Z_1, \dots, Z_n) | X_1, \dots, X_n] \\ &= \mathbb{E}_{\tilde{\theta}} \left[\ln \left(\prod_{i=1}^n h_{\theta}(X_i, Z_i) \right) | X_1, \dots, X_n \right] \\ &= \sum_{i=1}^n \mathbb{E}_{\tilde{\theta}}[\ln(h_{\theta}(X_i, Z_i)) | X_1, \dots, X_n] \end{aligned}$$

Or, les couples (X_i, Z_i) sont indépendants, donc

$$\begin{aligned} \mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n) &= \sum_{i=1}^n \mathbb{E}_{\tilde{\theta}}[\ln(h_{\theta}(X_i, Z_i)) | X_i] \\ &= \sum_{i=1}^n \sum_{j=1}^J \ln(h_{\theta}(X_i, j)) \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \end{aligned}$$

Nous nous appuyerons sur l'expression suivante pour l'expression des estimateurs du maximum de vraisemblance :

Proposition 7. *La fonction $\mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n)$ se réécrit sous la forme suivante :*

$$\begin{aligned} \mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n) = & -\frac{n}{2} \log(2\pi) + \sum_{j=1}^J \left(\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \right) \log(\alpha_j) \\ & - \frac{1}{2} \sum_{j=1}^J \left(\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \left(\log(v_j) + \frac{(X_i - \mu_j)^2}{v_j} \right) \right) \end{aligned}$$

Démonstration. Il suffit de partir de la forme précédente de la log-vraisemblance conditionnelle, on a ainsi :

$$\begin{aligned} \mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n) &= \sum_{i=1}^n \sum_{j=1}^J \ln(h_{\theta}(X_i, j)) \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \\ &= \sum_{i=1}^n \sum_{j=1}^J \ln(\alpha_j \gamma_{\mu_j, v_j}(X_i)) \times \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \\ &= \sum_{i=1}^n \sum_{j=1}^J (\ln(\alpha_j) + \ln(\gamma_{\mu_j, v_j}(X_i))) \times \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \\ &= \sum_{i=1}^n \sum_{j=1}^J \ln(\alpha_j) \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) + \sum_{i=1}^n \sum_{j=1}^J \ln(\gamma_{\mu_j, v_j}(X_i)) \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \end{aligned}$$

Traitons pour commencer la double somme

$$\Delta := \sum_{i=1}^n \sum_{j=1}^J \ln(\gamma_{\mu_j, v_j}(X_i)) \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)$$

Nous avons :

$$\begin{aligned} \gamma_{\mu_j, v_j}(X_i) &= \frac{1}{\sqrt{2\pi v(j)}} e^{-\frac{1}{2} \frac{(X_i - \mu_j)^2}{v_j}} \\ \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) &= \frac{\alpha_j \gamma_{\mu_j, v_j}}{\sum_{i=1}^J \alpha_j \gamma_{\mu_i, v_i}} \end{aligned}$$

La double somme devient alors

$$\begin{aligned}
\Delta &= \sum_{i=1}^n \sum_{j=1}^J \ln \left(\frac{1}{\sqrt{2\pi v_j}} e^{-\frac{1}{2} \frac{(X_i - \mu_j)^2}{v_j}} \right) \times \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \\
&= \sum_{i=1}^n \sum_{j=1}^J \ln \left(\frac{1}{\sqrt{2\pi v_j}} \right) \times \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) - \frac{1}{2} \left(\frac{(X_i - \mu_j)^2}{v_j} \right) \times \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \\
&= \sum_{i=1}^n \sum_{j=1}^J -\frac{1}{2} \ln(2\pi) \times \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) - \frac{1}{2} \ln(v_j) \times \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) - \frac{1}{2} \left(\frac{(X_i - \mu_j)^2}{v_j} \right) \times \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \\
&= -\frac{n}{2} \ln(2\pi) - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^J \left(\ln(v_j) + \frac{(X_i - \mu_j)^2}{v_j} \right) \times \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \\
&= -\frac{n}{2} \ln(2\pi) - \frac{1}{2} \sum_{j=1}^J \left(\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \times \left(\ln(v_j) + \frac{(X_i - \mu_j)^2}{v_j} \right) \right)
\end{aligned}$$

On obtient de fait le résultat espéré :

$$\begin{aligned}
\mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n) &= -\frac{n}{2} \log(2\pi) + \sum_{j=1}^J \left(\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \right) \times \ln(\alpha_j) \\
&\quad - \frac{1}{2} \sum_{j=1}^J \left(\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \times \left(\ln(v_j) + \frac{(X_i - \mu_j)^2}{v_j} \right) \right)
\end{aligned}$$

2

Nous allons dès à présent énoncer une proposition vitale, celle de l'expression des estimateurs du maximum de vraisemblance de la log-vraisemblance conditionnelle. L'expression de ces derniers seront le pivot de l'algorithme EM, que nous présenterons dans le chapitre suivant.

Proposition 8. *Sous l'observation de l'échantillon X_1, \dots, X_n et à $\tilde{\theta}$ fixé, la fonction $\theta \mapsto \mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n)$ admet un unique maximum θ_M donné par :*

$$\begin{aligned}
\hat{\alpha}_j &= \frac{1}{n} \sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \\
\hat{\mu}_j &= \frac{\sum_{i=1}^n X_i \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)}{\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)} \\
\hat{v}_j &= \frac{\sum_{i=1}^n (X_i - \mu_j)^2 \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)}{\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)}
\end{aligned}$$

Démonstration. Soit $\theta = (\alpha_j, \mu_j, v_j)$. Il s'agit ici de maximiser la fonction $\theta \mapsto \mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n)$

Puisqu'il s'agit d'un problème d'optimisation, on introduit le Lagrangien du problème sous la contrainte $\sum_{i=1}^n \alpha(i) = 1$. On rappelle que Le Lagrangien est défini ici par :

$$\begin{aligned}
L : \Theta \times R &\rightarrow R_+ \\
&: (\theta, \lambda) \mapsto \mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n) - \lambda \left(\sum_{i=1}^n \alpha_i - 1 \right)
\end{aligned}$$

Nous reprenons ici l'écriture de $\mathcal{L}_c(\theta, \tilde{\theta}, X_1, \dots, X_n)$ donné dans la précédente proposition, nous obtenons ainsi l'expression suivante du Lagrangien

$$\begin{aligned} L(\theta, \lambda) = & -\frac{n}{2} \log(2\pi) + \sum_{j=1}^J \left(\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \right) \log(\alpha_j) \\ & - \frac{1}{2} \sum_{j=1}^J \left(\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) \left(\log(v_j) + \frac{(X_i - \mu_j)^2}{v_j} \right) \right) - \lambda \left(\sum_{i=1}^n \alpha_i - 1 \right) \end{aligned}$$

Le Lagrangien admet un maximum sous la contrainte et ce maximum θ^* vérifie le système suivant :

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial \alpha_j}(\theta^*) = \frac{\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)}{v_j} - \lambda & = 0 \quad \forall j \in \llbracket 1, J \rrbracket \\ \frac{\partial \mathcal{L}}{\partial \mu_j}(\theta^*) = \sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) (-2X_i + 2\mu_j) & = 0 \quad \forall j \in \llbracket 1, J \rrbracket \\ \frac{\partial \mathcal{L}}{\partial v_j}(\theta^*) = -\frac{1}{2v_j} \sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) + \frac{1}{2v_j^2} \sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i) (X_i - \mu_j)^2 & = 0 \quad \forall j \in \llbracket 1, J \rrbracket \\ \frac{\partial \mathcal{L}}{\partial \lambda}(\theta^*) = \sum_{i=1}^n \alpha_i - 1 & = 0 \end{cases}$$


Puisque $\tilde{\theta}$ est fixé et l'échantillon X_1, \dots, X_n observé la loi conditionnelle $\mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)$ est donc une constante.

Le système devient alors :

$$\begin{cases} \alpha_j = \frac{\sum_{i=1}^n g_{\tilde{\theta}}(j | X = X_i)}{\lambda} & \forall j \in \llbracket 1, J \rrbracket \\ \mu_j = \frac{\sum_{i=1}^n X_i \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)}{\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)} & \forall j \in \llbracket 1, J \rrbracket \\ v_j = \frac{\sum_{i=1}^n (X_i - \mu_j)^2 \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)}{\sum_{i=1}^n \mathbb{P}_{\tilde{\theta}}(Z = j | X = X_i)} & \forall j \in \llbracket 1, J \rrbracket \\ \sum_{i=1}^J \alpha_i = 1 \end{cases}$$

Sous la contrainte $\sum_{i=1}^n \alpha_i = 1$ et la première équation du système précédent on obtient l'égalité suivante :

$$\begin{aligned}
\sum_{i=1}^J \alpha_i &= \sum_{i=1}^J \left(\frac{\sum_{j=1}^n \mathbb{P}_{\hat{\theta}}(Z = j | X = X_i)}{\lambda} \right) \\
&= \frac{\sum_{i=1}^J \sum_{j=1}^n \mathbb{P}_{\hat{\theta}}(Z = j | X = X_i)}{\lambda} \\
&= \frac{\sum_{j=1}^n \sum_{i=1}^J \mathbb{P}_{\hat{\theta}}(Z = j | X = X_i)}{\lambda} \\
&= \frac{\sum_{j=1}^n 1}{\lambda} = 1
\end{aligned}$$

On en déduit ainsi $\lambda = n$, ainsi que le résultat énoncé. 

Tous ces inesthétiques et fastidieux calculs n'ont pas été effectué en vain. Nous les avons réalisé suite à l'introduction d'une notion nouvelle, celle de la log-vraisemblance conditionnelle ; qui elle même à été introduite faute de ne pouvoir obtenir une expression analytique de la log-vraisemblance des observations. Nous allons maintenant tâcher de mettre en application les résultats obtenus dans cette section.

Chapitre 2

L'algorithme EM

Dans le présent chapitre, nous nous intéresserons A REMPLIR

2.1 Présentation laconique et pseudo-code

présentation textuelle rapide de l'algo : etape E, etape M etc...

Pour l'implémentation de cet algorithme, nous nous sommes appuyés sur le pseudo-code suivant.

Algorithm 1 L'algorithme EM (Dempster et al., 1977).

Entrée(s) : $N \in \mathbb{N}$, $\hat{\theta}_0 \in \Theta$, un jeu de données $x_1 \dots x_n$;

Initialisation ;

1: $k := 1$;

2: **Tant que** $K < N + 1$ **faire**

3: **ETAPE E** : Calculer la fonction $Q(\theta; \hat{\theta}_{k-1}) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_{\hat{\theta}_{k-1}} [\log f(X_i, Z_i, \theta) | X_i = x_i]$;

4: **ETAPE M** : $\hat{\theta}_k = \operatorname{argmax} Q(\theta; \hat{\theta}_{k-1})$;

5: $k \leftarrow k + 1$;

6: **fin du Tant que** ;

7: **retourner** $\hat{\theta}_N$;

2.2 Un théorème

Dans cette concise partie, nous donnons une preuve de la croissance de la log-vraisemblance conditionnelle au fur et à mesure des itérations de l'algorithme EM.

Théorème 1. *Soit $(\theta_k)_{k \in \mathbb{N}}$ la suite de paramètres construite à l'aide de l'algorithme EM. La log-vraisemblance \mathcal{L}_{obs} des observations vérifie*

$$\mathcal{L}_{obs}(\theta_{k+1}, X_1, \dots, X_n) \geq \mathcal{L}_{obs}(\theta_k, X_1, \dots, X_n)$$

Démonstration. Nous allons commencer cette preuve en donnant une autre forme de la log-vraisemblance, dépendant de $\mathcal{L}_{obs}(\theta, X_1, \dots, X_n)$ et d'un terme $\kappa_{\theta, \theta_k}$. Nous avons :

$$\begin{aligned} \mathcal{L}_c(\theta, \theta_k, X_1, \dots, X_n) &= \sum_{i=1}^n \sum_{j=1}^J \ln(h_\theta(X_i, j)) \mathbb{P}_{\theta_k}(Z = j | X = X_i) \\ &= \sum_{i=1}^n \sum_{j=1}^J \ln[f_\theta(X_i) \times \mathbb{P}_\theta(Z = j | X = X_i)] \mathbb{P}_{\theta_k}(Z = j | X = X_i) \\ &= \sum_{i=1}^n \sum_{j=1}^J \ln(f_\theta(X_i)) \mathbb{P}_{\theta_k}(Z = j | X = X_i) + \sum_{i=1}^n \sum_{j=1}^J \ln(\mathbb{P}_\theta(Z = j | X = X_i)) \mathbb{P}_{\theta_k}(Z = j | X = X_i) \\ &= \sum_{i=1}^n \ln(f_\theta(X_i)) \times \underbrace{\sum_{j=1}^J \mathbb{P}_{\theta_k}(Z = j | X = X_i)}_{=1} + \sum_{i=1}^n \sum_{j=1}^J \ln(\mathbb{P}_\theta(Z = j | X = X_i)) \mathbb{P}_{\theta_k}(Z = j | X = X_i) \\ &= \sum_{i=1}^n \ln(f_\theta(X_i)) + \sum_{i=1}^n \sum_{j=1}^J \ln(\mathbb{P}_\theta(Z = j | X = X_i)) \mathbb{P}_{\theta_k}(Z = j | X = X_i) \\ &= \mathcal{L}_{obs}(\theta, X_1, \dots, X_n) + \kappa_{\theta, \theta_k} \end{aligned}$$

Dès lors, on obtient

$$\mathcal{L}_{obs}(\theta_{k+1}, X_1, \dots, X_n) - \mathcal{L}_{obs}(\theta_k, X_1, \dots, X_n) = \mathcal{L}_c(\theta_{k+1}, \theta_k, X_1, \dots, X_n) - \kappa_{\theta_{k+1}, \theta_k} - \mathcal{L}_c(\theta_k, \theta_k, X_1, \dots, X_n) + \kappa_{\theta_k, \theta_k}$$

Or, la quantité \mathcal{L}_c est maximisée en θ_{k+1} lors de l'étape M de l'algorithme, donc

$$\mathcal{L}_c(\theta_{k+1}, \theta_k, X_1, \dots, X_n) - \mathcal{L}_c(\theta_k, \theta_k, X_1, \dots, X_n) \geq 0$$

Il reste donc à prouver que

$$\kappa_{\theta_k, \theta_k} - \kappa_{\theta_{k+1}, \theta_k} \geq 0$$

En effet, nous avons

$$\begin{aligned}
\kappa_{\theta_k, \theta_k} - \kappa_{\theta_{k+1}, \theta_k} &= \sum_{i=1}^n \sum_{j=1}^J \ln(\mathbb{P}_{\theta_k}(Z = j|X = X_i)) \mathbb{P}_{\theta_k}(Z = j|X = X_i) \\
&\quad - \sum_{i=1}^n \sum_{j=1}^J \ln(\mathbb{P}_{\theta_{k+1}}(Z = j|X = X_i)) \mathbb{P}_{\theta_k}(Z = j|X = X_i) \\
&= \sum_{i=1}^n \sum_{j=1}^J \ln\left(\frac{\mathbb{P}_{\theta_k}(Z = j|X = X_i)}{\mathbb{P}_{\theta_{k+1}}(Z = j|X = X_i)}\right) \mathbb{P}_{\theta_k}(Z = j|X = X_i) \\
&= - \sum_{i=1}^n \sum_{j=1}^J \ln\left(\frac{\mathbb{P}_{\theta_{k+1}}(Z = j|X = X_i)}{\mathbb{P}_{\theta_k}(Z = j|X = X_i)}\right) \mathbb{P}_{\theta_k}(Z = j|X = X_i) \\
&\geq - \sum_{i=1}^n \ln\left(\sum_{j=1}^J \frac{\mathbb{P}_{\theta_{k+1}}(Z = j|X = X_i)}{\mathbb{P}_{\theta_k}(Z = j|X = X_i)} \mathbb{P}_{\theta_k}(Z = j|X = X_i)\right)
\end{aligned}$$

[Cette dernière inégalité est due à la convexité du \log et au fait que $\sum_{j=1}^J \mathbb{P}_{\theta_k}(Z = j|X) = 1$]

$$\begin{aligned}
&= - \sum_{i=1}^n \ln\left(\sum_{j=1}^J \mathbb{P}_{\theta_{k+1}}(Z = j|X = X_i)\right) \\
&= - \sum_{i=1}^n \ln(1) \\
&= 0
\end{aligned}$$

On obtient ainsi

$$\kappa_{\theta_k, \theta_k} - \kappa_{\theta_{k+1}, \theta_k} \geq 0$$

Et finalement

$$\mathcal{L}_{obs}(\theta_{k+1}, X_1, \dots, X_n) \geq \mathcal{L}_{obs}(\theta_k, X_1, \dots, X_n)$$

2

Bibliographie

Liens utiles

<https://www.lpsm.paris/pageperso/rebafka/BookGraphes/algorithmem.html>
<https://members.loria.fr/moberger/Enseignement/AVR/Exposes/algo-em.pdf>
http://faculty.washington.edu/fxia/courses/LING572/EM_collins97.pdf
<https://core.ac.uk/download/pdf/155777956.pdf>
<http://www.cmap.polytechnique.fr/~bansaye/CoursTD6.pdf>

Annexe A

Annexe